

[PRD] ByteHi Manual Annotation Tool - New Rule

Basic Info

Change Log

Date // 日期	Description // 描述	修改人 // by
2026-06-23	Document Creation	 Aaron Wen

Relevant Links

Link to Meego Ticket	 [Features][CSP] 人工标注工具支持评估新规则（AI coding）	 Aaron Wen
Link to Figma/Demo	TBD	 Aaron Wen
Link to Event Tracking	TBD	 Aaron Wen
Other Useful Links	1. 服务评估 - 新标准梳理 2. [PRD] AI Evaluation phase 2.2 3. Manual annotation tool // 人工标注工具 4. [PRD] ByteHi Manual Annotation Enhancement Features	 Aaron Wen

Intro & Goal

What are we building?

本项目旨在升级 **ByteHi Manual Annotation Tool**，以适配最新的客服服务评估标准：整体北极星指标为 **用户满意分（User Experience Score）**，由 **服务质量分（Service Quality Score, SQS）** 与 **用户预期达成（User Expectation Fulfillment）** 共同构成。工具侧需要支持按当前生效的评分标准版本进行标注、展示、导出与历史结果追溯。

核心改动点包括：

- 1. 规则隔离：在任务列表及详情页实现新旧规则的**完全隔离**，避免污染。
- 2. 打分架构重构 [NEW]：将原有的 P/Q/I 架构替换为最新版 **用户满意分** 框架：服务质量分（SQS）包含理解准确性、执行正确性、方案采纳、响应及时性、服务效率、语言质量 6 个维度；用户预期达成作为独立用户视角评分；最终用户满意分按当前生效的标准版本计算。
- 3. 标准版本与自动化辅助逻辑 [NEW]：工具不内置旧版一票归零 / Gatekeeper 规则。评分字段、分档、权重、自动计算与校验逻辑均应由当前生效的评分标准版本驱动。系统可提供负向信号提示等辅助能力，但不得替代人工确认，也不得在标准未定义的情况下自动将其他维度归零。其中 **响应及时性（Responsiveness）** 按最新标准由系统根据响应时间戳自动判定，跳过该维度的人工标注（展示为只读，不参与人工打分 / 编辑）。[服务评估 - 新标准梳理](#)
- 4. 上下文增强 [NEW]：集成 Skill Flow、变量值及用户反馈信号，支撑标注人进行精准判定。

Why build it?

- 1. 对齐集团服务评估新标准：现有的 GE Rate (优良率) 体系已无法满足对智能/人工服务进行“平台标准执行”与“用户主观体验”的双重精细化评估需求。[服务评估 - 新标准梳理](#)
- 2. 作为 AI Evaluation 的 Ground Truth 生产线：人工标注结果是衡量 AI 自动评估准确率的基准。工具必须提供结构化、可审计的标注产出。
- 3. 提升标注效率与一致性：通过 Score-first 的引导式交互及内置 Rubric 助手，降低标注人的心智负担，减少人为判分误差。[\[PRD\] ByteHi Manual Annotation Enhancement Features](#)

How to define success?

Success Metrics

- 1. 能跑通，无明显逻辑bug

Requirement Detail

User Interaction & Design

本部分所有新部分的"Expected Design"图片皆为前端静态Template



场景 // Scenes	交互描述（中文） Interaction Description (CN)	目前存在问题 / 当前设计 Current Problems	预期设计 Expected Design
首页部分			
首页 - Case		1. 显示 GE Rate 及其 P/Q/I breakdown 进度	1. 显示新版标准以及当前评分标准版本

Set

1. 在首页顶部切换 Old Rule / New Rule。切换到 New Rule 后，列表、指标和后续操作都按新规则展示。做新 / 旧规则的彻底隔离。

2. 取代 GE Rate，每行 case set 展示：

- **Cases**：该 case set 的总条数。
- **Assigned**：已分配 / 总数（只要不是 Unassigned 就算已分配）。
- **Completed**：已完成 / 总数（第一轮 A 评完及之后）。已分配与已完成是两件事，分开展示。
- **SQS Avg**：展示 case set 下已完成标注的平均服务质量分，例如 2.43 / 3。
- **用户预期达成 Avg**：展示 case set 下用户预期达成的平均分
- **用户满意分 Avg / User Experience Score Avg**：展示由 SQS 与用户预期达成按当前标准版本计算后的整体平均分。
- **SQS Pass Rate**：已评分 case 中 pass 的占比，例如 78.5%
- **QC Accuracy**：展示审核一致率（该 case set 中被 C 定案的 case 里，C 最终打分与 A 原始打分完全一致的占比），例如 100.0%；无定案显示 -。





首页 - 导入 Sample

1. 导入 sample 后，系统解析 session link、session id、service form、channel、entrance、service type、annotator 等基础字段。

1. 现有导入窗口
2. session信息直接在左侧窗口看，暂时无法直观显示是否已经分辨出Skill、SOP 与 FAQ。

1. 不变，大体维持原设计
2. 自动分辨Skill、SOP 与 FAQ，并且将部分信息置于评分表顶部

2. 系统识别 Knowledge Source, 优先区分 Skill、SOP 与 FAQ。
3. 自动抓取 problem type (R1 / R2 / R3) ; FAQ 默认按 R1 信息类处理, 除非系统已有更明确的问题类型。



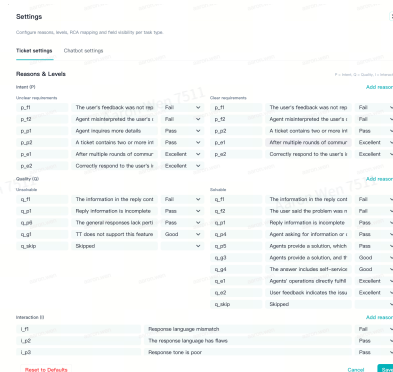
首页 - Settings [NEW]

Settings

1. 点击 New Rule 首页右上角 Settings 后, 打开 New Rule SettingsSettings 只服务 New Rule, 不展示也不兼容 Old Rule 配置。
2. User Satisfaction (North Star) Weights: 用户可以在这里调整 SQS 和 UES 对新的北极星指标的权重。
3. 用户可以在这里点击解锁, 编辑 SQS 和 UES 的 reasons, 但是只能添加, 不能删除/修改旧的 SQS/UES指标构成部分 (比如只能添加新的指标, 不能修改/删除Understanding Accuracy) 这样做的目的是防止串版本。用户唯一可以修改的是旧的 SQS UES 指标里的文案。
4. 用户在添加新的指标, 或者对现有指标进行打开/关闭, 并且点击 Apply changes 时, 会提示创建了新的 rubric。目前暂无切换 rubric 功能。
5. Config Version / Effective Time: 用户添加的所有 rubric 会在这里找到新的版本号以及具体生效时间。
6. 为了防止版本错乱, 本页设置了如解锁、修改确认等方式, 保护用户免于误修改。

New Rule 是独立工作区。旧版已在入口层隔离, 因此本 Settings 不处理 Old Rule, 也不需要为 Chatbot、Ticketbot、Human Service 或 E2E 分别维护多套配置。

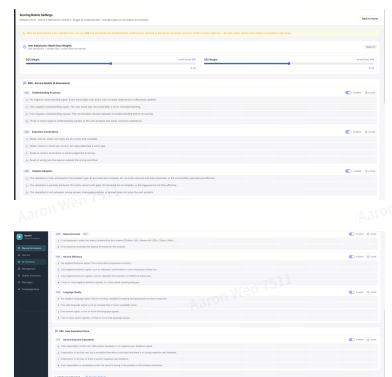
1. Reasons 旧版, Chatbot与 Ticket因旧标准当中内容不同而分离




2. 旧版本的版本管理与新版本一致, 均为添加新指标来防止版本错乱, 但缺少版本管理和版本记录。

New Rule Settings 只保留辅助配置模块, 并补充标准版本展示与配置版本管理:

1. Reason Templates, 展示 / 修改不同分数文案, 并修改北极星指标下的权重。



2. 可从该窗口构建新标准 (default为2026.7.1标准版本)



3. Config Version / Effective Time 版本管理



首页 - Batch Assign [NEW]

Assign

- 和detail当中按单个case assign不同，在首页是批量 assign
- 在原有基础上添加OA名联想检索，后期可加 Annotators 名单支持这一功能，本期暂时不上，填什么理论都可以。
- 可改变上方 remaining unassigned case 数字。让分配所剩任务变得一目了然。
- 分配后的逻辑是，可填多个 QA name + 各自 quantity，按填写顺序依次切分未分配的 case（比如，A 同学分配了两条，就拿从上到下1和2号 case；B 同学被分配了三条，就拿3号、4号和5号 case）
- 【重要】添加Back to Back模式，可将：
 - case set整个定义为b2b / Normal，是b2b模式的开关
 - 选择b2b模式后在detail 当中可看到展开的菜单

- 目前的 assign 流程支持输入姓名和数量

- 无法输入数字，倒数上面所剩任务，可能出现潜在的计算错误。

Remaining unassigned: 9 cases

QA Name	Quantity
q	1
w	2

- 不支持Back to Back分配流程，该流程在原流程中属于难以解决、链路很长的痛点

在原有内容基础上，添加：

- QA名支持搜索

- Back to Back模式：

- 输入分配 case 数字，可改变上方 remaining unassigned case 数字。Back to Back模式下相同。

- 1

- Detail 是进入某个 case set 后的 individual session list。New Rule task 进入 Detail 后只展示 New Rule 相关字段。
- 表格保留 Session ID / Task ID、Service Subtype (Chatbot / Ticketbot)、Knowledge Source (Skill / SOP / FAQ)、Assign QA、**Status**、**Actions**、Latest Activity Log 等基础列。
- 页面替换为 SQS 六维度 + 用户预期达成 + 用户满意分结果列 (Understanding Accuracy、Execution Correctness、Solution Adoption、Responsiveness、Service Efficiency、Language Quality、SQS Total、UES、User Satisfaction 北极星、Transfer to human 是否转人工)。其中 Transfer to human 由系统自动识别，展示为只读 Yes / No，不可人工切换。
[NEW]
- SQS、UES 两列表头可点击展开 / 收起**，展开后展示该组下各维度的具体分数与 reason。
[NEW]
- 点击 Session ID 进入该 session (原设计)
- Filter: Service Subtype (Ticket / Chatbot)、Knowledge Source (Skill / SOP / FAQ)、Problem Type (R1 / R2 / R3)、SQS (Pass / No Pass)、Human Result (是否转人工: Has Human / Bot Only)。
[NEW]

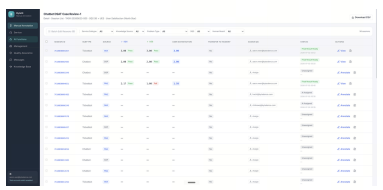
当前 Detail 是按 session 展开的宽表，指标仍是旧 GE Rate / P-Q-I 体系

1.




5.

1. 见交互描述



2. SQS / UES 可展开 / 收起




7. 可以点击每个 case 的“Assign QA”按钮为单条 case 分配 / 改派 annotator（见下文详细描述）：
- a. 该 case 还没人评（Unassigned）→ 指派后进入标注流程、状态变 A Assigned，该人成为这条的标注人；
 - b. 该 case 已在流程中（已提交 / 在 QC / 已结束）→ 只改负责人标签，**不会把流程打回、也不覆盖已记录的标注人。**
8. **Status**（列出所有状态，详情见下方描述）**[NEW]**
9. **Actions**（不同账号看到的动作，系统按当前用户与 case 状态解析出唯一动作，用于日常标注和QC，详情见下方）：**[NEW]**
10. 版本管理：每条结果记录提交时使用的评分标准版本详见文档下方 Activity Log 部分的说明。**[NEW]**


首页 - Detail - Session List - Status **[NEW]**

1. **Status**（列出所有状态，建议和下方Actions共同理解）：**[NEW]**
- a. Unassigned：未分配。
 - b. A Assigned：已分配、等待**第一轮**标注。
 - c. Completed Annotation：第一轮标注已提交（尚无人二次评）。
 - d. Back-to-Back Completed：有人做了 Review并提交（该 case 成为双盲）。
 - e. Selected for QC：已被抽样、进入 C 复核队列。

1. 旧版仅显示“Latest Activity Log”表示当下case状态



1. Status 图览 (取缔旧版 Latest Activity Log)



f. Final Result Ready : C
已定案，最终结果留存。

首页 -
Detail -
Session List -
Actions
[NEW]

Actions (不同账号看到的动作，系统按当前用户与 case 状态解析出唯一动作，用于日常标注和QC，详情见下方)：

[NEW]
用一个例子来加强理解：小A，小B，小C

- 尚未有人第一轮评 → 「Annotate」；
 - 小A此时做了评分
- 已评，且是小A本人 → 仍「Annotate」，小A可继续修改自己的结果（直到有人二次评或被C定案）；
- 已评，且不是小A，如小B → 看到的是「Review」
 - 小B以二次评审身份做Back to Back；
- 已被小B二次评完 / 已被小C QC完毕 → 「View」，只读查看；
- 小A自己作为第一轮 case 的评委，不能再对同一条做B2B / QC（详情见下方QC类流程），小B也不能对自己B2B后的 case 做QC，只能交给小C

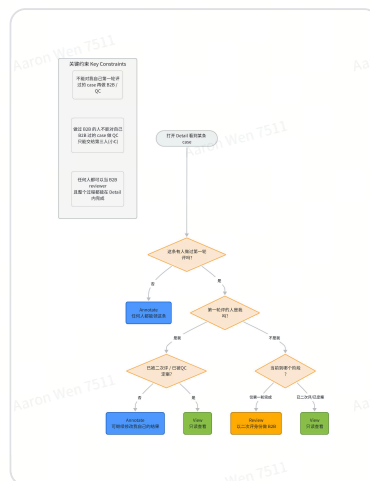
因此，逻辑上是，任何人都可以是B2B的reviewer，且在Detail里就可完成这一切。

换句话说来说，

新版的三种角色（都不是固定的人，由"谁先动了这条 case"动态决定）：

- 旧版对于不同账号仅有一种状态显示，即 Edit Annotation，标注人若想做 Back to Back，需要盯着 Latest Activity Log 和评分状态，逐条检查此 case 的标注状态，才能判断自己该 Annotate 还是 Review，成本高、易出错。
- 旧版不区分角色，也没有防自审：无法阻止标注人复核自己评过的 case，B2B / QC 的责任归属靠人工约定，不在系统层面保证。
- 旧版没有只读态：即便 case 已被复核 / 定案，入口仍是 Edit Annotation，存在被误改、覆盖最终结果的风险。

1. Actions图览



- 1. 标注员A：第一个评了某条 case 的人。
- 2. Reviewer B：剩下的任何人——只要不是这条的 A，都可以对它做 Back-to-Back 二次评（团队可灵活按照自己规则，自行分配）。
- 3. QC / C：既没做过这条的第一次标注、也没做过它的二次评的第三人，才能做最终 QC 复核（overwrite 定案）。

这样设计的好处：角色由行为动态产生 + 系统自带防自审，能适配大多数团队的标注 / QC 流程，而不用为每个团队写死一套分工。

一般团队的标注 / QC 流程通常是：

- 1. 规则爬坡期（追准确率）：用接近 100% 的双人互检——A 先评，B 再对同一批做 Back-to-Back，牺牲一点产量换高准确率。对应到本工具：A Annotate → 任意 B Review，这条即成 Double-blind。
- 2. 规则稳定期（追产量）：改为单人产出为主 + 抽检——A 单独评完即可，C 只对其其中抽样的部分做 QC，放大产量。对应到本工具：A 评完即进 QC 可抽样池 → 在 Audit 里 Set Sampling → 抽中的由 C 复核定案。
- 3. 两阶段可无缝切换：因为进 QC 的门槛统一是"A 已评完"，是否形成双盲只取决于"有没有人来做 Review"，团队随时可以从"人人互检"过渡到"只抽检"，工具不需要改配置、也不锁死分工。

1. Assign QA 保持现有入口，但需要把状态表达清楚：如果 case：
 - a. 没有 owner，点击分配后状态是 **Distribute**
 - b. 如果 case 已经有 owner，点击后是 **Reassign**（现在是如果这个case没人负责，在 detail里面assign QA的结果状态也是 “reassign”）
2. Assign / Reassign 只改变该 session 的负责关系，不改变评分结果，也不自动生成 annotation result。
3. QA Owner 列继续展示当前 owner；Annotator 继续展示当前被分配的 annotator。
4. Latest Activity Log 中的邮箱表示“谁执行了这次修改 / 操作”，不是“谁被分配为 annotator”。例如 Assign、Reassign、Edit Annotation 都需要记录 operator email、时间和变更字段。

现有 Detail 已有 row-level **Edit Annotation** 和 **Assign QA**。Assign 弹窗支持输入 QA name 和 quantity；Latest Activity Log 展示 Edit / New、operator email、时间和字段变更。这里的 log email 是修改人，不是被分配的 annotator。[Manual annotation tool // 人工标注工具](#)

New Rule 不改变分配模型，只补齐状态语义和日志语义：无主时为 Distribute，有主时为 Reassign；log email 明确为 modifier / operator。Edit Annotation 的表单内容改为 SQS 六维度、用户预期达成、用户满意分，并复用 Bot Result / Human Result 同一套当前生效评分标准版本。[服务评估 - 新标准梳理](#)

	5. Edit Annotation 打开该 session 的 New Rule annotation form。若已有标注结果，则预填当前 SQS 六维度、用户预期达成、用户满意分、Human Result（如适用）及其 <code>standard_version</code> / <code>rubric_version</code> / <code>config_version</code>，并允许编辑（其中响应及时性由系统根据时间戳自动判定，展示为只读、不可人工编辑）。提交后 Activity Log 记录本次修改字段，例如 Understanding Accuracy、Execution Correctness、Solution Adoption、Responsiveness、Service Efficiency、Language Quality、用户预期达成、用户满意分 Total、Reasoning、<code>standard_version</code>。所有角色的基础定义		

Annotation页面

Annota tion - 评分页 面 [NEW]	1. 左侧为【evidence】（对话），占页面宽度约 60%；右侧为【评分区】，占页面宽度约 40%。 a. 展示 AI Service conversation 作为 evidence； i. 当 Service Subtype = Chatbot 时展示 session conversation	1. 当前版本的左侧chatbot基于html富文本抓取，ticket 基于session information窗口 2. 旧标准，旧UI 3. 旧标准本身无/不适合做分数总览	1. 沿用“左 evidence、右评分”的低学习成本布局。新版本的chatbot和ticket 都采用session information窗口 2. annotator 可以直接点击 0 / 1 / 2 / 3 等分数（或者 reasons，二者绑定），同时进行UI小优化 3. SQS/UES总览
---	--	--	--

	ii. 当 Service Subtype = Ticketbot 时展示 ticketbot thread / bot reply evidence。 考虑到 Chatbot 与 Ticket 最大的共同点是各自作为【对话】的本质，将二者合并为【对话】，正好也适配 Session list 对话记录改版 - https://www.figma.com/design/cfHEixnLt3se0xaUut2APG/ByteHi-2026H1?node-id=3449-135417&t=yFfwFDCPwDKcVxs4-1 iii. 二者都用原ticket的 session窗口显示 2. 顶部展示总分预览 3. 评分选项应直接展示在页面上，annotator 可以直接点击 0 / 1 / 2 / 3 等分数（或者 reasons，二者绑定），不需要为了选择分数再打开多层下拉。		
评分标准版本管理	1. 系统通过评分标准版本管理控制当前生效的评分字段、分档、权重、自动计算、校验与导出字段。 2. 每个 annotation result、review result、AB Common Sense、final result 都需要记录提交时使用的 <code>standard_version</code> / <code>rubric_version</code>，以及辅助配置的 <code>config_version</code>。	原 PRD 将 Understanding Accuracy = 0 自动归零下游字段作为固定 hard gating；但最新标准未定义该规则，且已删除原体验缺陷一票否决口径。	以标准版本管理替代硬编码规则。当前版本按 服务评估 - 新标准梳理 的维度和分档执行；后续如标准 owner 新增 gating / 权重 / pass-fail 规则，由新版本配置生效，并在历史结果中可追溯。

	3. 当评分标准版本更新时，历史结果不自动重算、不静默覆盖；如需重算，必须通过明确的 re-evaluation / migration 流程生成新版本结果。		
SQS - Understanding Accuracy	1. annotator 阅读对话，按“负向理解信号”数量选择 3/2/1/0，并填写 reasoning。 3分：未出现负向理解信号。 2分：出现 1 个负向理解信号。 1分：出现 2 个负向理解信号。 0分：出现 3 个及以上负向理解信号，或始终没有正确理解用户问题 / 进入错误服务能力或知识载体。 2. 系统可展示候选 negative signals，但最终以人工确认结果为准。	旧规则	待新规则对齐，随时调整ui和逻辑
SQS - Execution Correctness	1. 系统自动识别并切换对应类型：Skill、SOP、FAQ。 2. Skill 路径：annotator 判断 C1 Route / Stage、C2 Branch / Scenario、C3 Action / Reply 是否正确，并选择 3/2/1/0。 3. FAQ 路径：不需要判断 route / branch / action，只判断回答是否正确且完整；仅提供 3/1/0，不提供 2 分。 4. SOP 路径：由于当前缺少稳定的 SOP input / flow evidence，本 MVP 暂不求完整打分；	旧规则	待新规则对齐，随时调整ui和逻辑
SQS - Solution		旧规则	待新规则对齐，随时调整ui和逻辑

Adoption	- 展示 Problem Type: R1 Information、R2 Personalized Info、R3 Operation（由系统字段自动读取；异常时走数据问题反馈，不在标注页直接改写） - 展示 Signal Priority: P0 Objective System Signal 或 P1 Content Evaluation。 - annotator 选择 3/1/0；本维度没有 2 分。		
用户满意分结构	- 本版本不再使用“UES 四维度”表述。最新标准下，整体 用户满意分（User Experience Score） 由 服务质量分（SQS） 与 用户预期达成（User Expectation Fulfillment） 共同构成。 - SQS 包含 6 个维度：理解准确性、执行正确性、方案采纳、响应及时性、服务效率、语言质量。 - 用户预期达成单独评分，结合 P3/P4 用户反馈信号与 P2 内容评估判断用户预期是否被满足。 - 用户满意分 Total 按当前生效的评分标准版本计算；如果权重或计算方式仍待定，工具展示为版本配置项，不在前端硬编码。	旧规则	待新规则对齐，随时调整ui和逻辑
Submit & Export	提交后支持下载两个文件：	当前下载样例有两个文件： <code>annotation_summary.csv</code> 是汇总结果， <code>annotation_data.csv</code> 是逐条 session 明细。旧版 data 文件字段包括 imSessionId、language、regionCode、rowList、piScore / piReason、rqScore / rqReason、ieScore /	保存、提交后可在首页 download 导出 CSV。导出结果需与 evaluation platform 兼容，并明确区分 summary 和 data 两层文件。 新版指标字段需要替换为 SQS 六维度、用户预期达成、用户满意分 Total，并补充关键 timestamp 与版本字段。

	◦ <code>annotation_summary.csv</code>：汇总层文件，用来看整体结果，例如已标注量、总样本量、SQS Avg、用户预期达成 Avg、用户满意分 Avg、SQS Pass Rate（如当前标准版本定义）、QC Accuracy。 ◦ <code>annotation_data.csv</code>：明细层文件，一行对应一个 session / case，用来看每条标注结果和原因。 2. New Rule 导出的 data 文件应保留基础字段，例如 session id、language、region、conversation / evidence； 3. Human Result 仅在系统识别到转人工证据时出现；纯 Bot case 不要求填写 Human Result。 4. <code>annotation_data.csv</code> 需要输出关键时间字段，比如 imported_at、assigned_at、annotation_submitted_at、review_submitted_at、final_result_at、last_activity_at。	ieReason、solvingAbility、overallExperience 等，新版导出应该也遵循此方式； Data: file_file_新框...147.70KB  Summary: file_file_新框...263 B 	
Human Result [NEW]	如系统识别到： • Bot to Human IM • Bot to Human Ticket 则自动展示一个额外的 Human Result 表单，表单结构与 Bot Result 保持一致。		同 Bot Result；仅在系统识别到转人工证据时自动展示。
QC阶段			
QC / Audit - Definiti		现有 Audit 入口能力参考 Manual annotation tool // 人工	1. 保守修改，沿用现有 Audit 入口处理 QC / review；

on & Modes [NEW]	1. 在本工具中，Audit 仍是 QC / review 的唯一产品入口，用于抽样复核、查看结果、提交 review decision / final result。 2. 一轮标注的质量保障分成两种互斥模式，同一个任务 / 批次只启用其中一种，通过任务配置切换（沿用首页 Old Rule / New Rule 的开关思路）： a. 双盲模式 / Double-blind（规则准确率爬坡期使用，牺牲产量换准确率，接近 100% 互检；A/B 双盲标注 b. 单人 + 抽检模式 / Single + Sampling（规则准确率稳定后使用，A 单人产出为主，C 对已提交结果抽样复核，放大产量）。两种模式不同时存在；何时从双盲切到抽检由运营 / 业务按准确率稳定度决定。本版本只提供模式开关，不在工具内硬编码切换条件。 3. 平台不强行定义团队分工，但需要把当前模式、A/B/C 角色、状态和结果版本都记录清楚。	标注工具；双盲与抽检为互斥的两个阶段。	2. 双盲与抽检做成互斥的模式开关（类比 Old / New Rule 切换），本版本不实现两种模式的自动切换或混用。
QC / Audit - Back-to-back Blind Review [NEW]	1. 本流程只在双盲模式下发生：A 和 B 作为一轮标注者分别提交 A Result / B Result。 2. B 提交前看不到 A Result，A 提交前也看不到 B Result。 3. A 与 B 均提交后，系统才允许进入 compare / mismatch view。	A/B 盲评是为了避免互相影响；mismatch 只有在双方都提交后才应该被打开。该流程来自用户最新会议说明，并需对齐 智能月会 - 新标准更新梳理	交互建议：页面可复用现有三栏基础结构，但 double-blind 阶段不展示对方结果；双方提交后才打开 mismatch compare。

	- 若 A/B 没有 mismatch，直接形成 AB Common Sense。 - 若 A/B 有 mismatch，系统展示不同维度、分数、reasoning 和 evidence，进入讨论状态。 - 双盲模式默认没有 C 抽检，归一后的 AB Common Sense 即为该 case 的 final result。		
QC / Audit - Mismatch & AB Common Sense [NEW]	- 点击 mismatch 后，A 和 B 能看到彼此差异。 - Mismatch compare 需要按维度展示 A Result、B Result、diff、各自 reasoning、evidence anchor。 - A/B 讨论后，必须提交一个 AB Common Sense；在双盲模式下它就是该 case 的最终结果，默认不再进入 C（除非切到"双盲 + 抽检"的预留流程，见 Sampling & C Review 行）。 - AB Common Sense 不直接覆盖 A Result 或 B Result；三份记录都需要保留，用于追溯。 - 每次从 mismatch 到 common sense 的变动都记录 Activity Log。	用户明确说明 A/B 在看到 mismatch 后可以 argue，并达成 common sense。在双盲模式下，该 common sense 是 A/B 归一后的最终结果，而不是简单 override，也不默认送入 C。 智能月会 - 新标准更新梳理	保守实现：不做实时协同编辑，先支持差异对比、最终共识提交、版本留痕。讨论本身可以在线下或评论中完成。
QC / Audit - Sampling & C Review [NEW]	本流程属于"单人 + 抽检"模式，与双盲互斥：C 对已提交的单人 annotation records 抽样复核。	现有 Audit 弹窗已经支持 All QAs / By QA、Percentage / Absolute number、Completed annotations、Estimated samples、Start sampling，可作为抽样能力基础。 Manual annotation tool // 人工标注工具；双盲与抽检是互斥的两个阶段，不在同一条流水线里叠加，抽检默认作用于单人标注结果（依据用户 2026-07-	保留现有 Sampling UI 的比例 / 绝对数量能力；文案上明确抽检默认作用于单人标注结果，双盲模式默认不进入抽检。

	2. Sampling scope 支持: All Completed Records / By Annotator / By Service Subtype / By Knowledge Source / By SQS Fail / By SQS Dimension / By 用户预期达成 Score / By 用户满意分区间 / By standard_version。 3. Sampling method 继续复用 Percentage 和 Absolute number; 系统展示 Completed Records、Estimated C Review samples, 并生成 C review list。 4. C 查看被抽中的 annotator result, 提交 review decision / final result; 如存在 disagreement, 需要保留讨论后的最终结果。 5. 保守留白: 若团队希望在双盲之后再加第三人抽检, 前提是两位双盲同学先确认出唯一的 final 答案, 再把该 final 结果作为抽检对象; 此"双盲 + 抽检"组合流程本版本暂不展开, 仅作预留。	01 说明)。智能月会 - 新标准更新梳理	
QC / Audit - Review Page & Logging [NEW]	1. Audit / review 页面仍建议固定为三栏: Original Session / Evidence、Annotator Result / Compare、Review Mode。页面按当前模式切换展示, 不同时出现两种模式。 2. 双盲模式 · 盲评阶段: 左栏展示原始会话; 对方结果在双方提交前不可见; 当前用户只填写自己的 annotation result。 3. 双盲模式 · mismatch 阶段: 中栏展示 A Result vs B Result 的差异; 右栏填写 AB Common Sense。	当前 Audit 页面已经呈现“左侧原始窗口 + 中间结果摘要 + 右侧 Review Mode”的基础结构, 可复用为新流程不同状态下的三栏页面。Manual annotation tool // 人工标注工具; A/B/C common sense 流程来自用户最新会议说明和 智能月会 - 新标准更新梳理	

	4. 单人 + 抽检模式 · C review 阶段：中栏展示被抽中的单人 annotator result；右栏填写 C decision / final review result。 5. Final result 取决于当前模式： • 双盲模式：使用归一后的 AB Common Sense； • 单人 + 抽检模式：被抽中样本用 C review 后的结果，未抽中样本用单人 annotator result； • A Result、B Result、AB Common Sense、C decision 都作为历史版本保留。Activity Log 需要记录 mode、A submit、B submit、mismatch reveal、AB Common Sense submit、sampling to C、C decision、final result submit 等关键动作。		
--	--	--	--

其他

Activity Log [NEW]	1. Timestamp 是业务事件发生时间，例如 message time、bot response time、transfer time、annotation submit time；Time Log / Activity Log 是平台操作流水，例如谁在什么时候分配、标注、修改、复核、导出。 2. Detail 列表只展示一行 Latest Activity Log，用于快速看最近一次动作，格式为：Action · Operator · Time ，	现有 Detail 已有 Latest Activity Log，用于展示最近一次 Edit / New、operator email、时间和字段变更。当前 PRD 中 timestamp 同时被用于 Responsiveness 预填和操作日志，容易混淆，因此需要在产品口径上明确区分 evidence timestamp 与 platform time log。Manual annotation tool // 人工标注工具	本版本先做保守方案：Detail 列表展示最近一条日志；完整 Time Log 放在详情内；CSV 至少输出关键时间字段。完整 activity_log.csv 可以作为后续增强，不阻塞本期功能。
----------------------------------	---	--	---

a. 例如 `Submit Annotation · aaron.wen · 2026-06-23 19:42:11 PDT`。

3. 点击 Latest Activity Log 后打开完整 **Activity Log / Time Log**，按时间倒序展示完整流水。每条 log 至少包含：Action、Operator、Role、Timestamp、Status Change、Changed Field、Before、After、Note。

4. CSV 输出中，`annotation_data.csv` 需要带关键 timestamp 字段：`imported_at`、`assigned_at`、`annotation_started_at`、`annotation_submitted_at`、`review_started_at`、`review_submitted_at`、`final_result_at`、`last_activity_at`。如果某个流程没有发生，对应字段留空。

5. 完整操作流水不塞进 summary CSV；如需要导出，放在 data CSV 的 `activity_log_json` 字段或后续单独提供 `activity_log.csv`。

Checklist

☒ 功能闭环

☐ 后端数据闭环，跑通

Appendix

Options Considered

1. **单一表单动态开关:** 考虑过在同一表单里通过开关切换新旧规则。

- **决策:** 否决。因新旧规则对 Context 数据需求差异巨大，强行整合会增加前端渲染及数据校验的复杂度。

2. **将现有Skill小工具整合进平台:** 曾考虑过三部分布局，左上：conversation，左下：annotator需调用的工具，右：评分表

- **决策:** 否决。暂时无需考虑，复杂程度较高。

3. **优化QC体验，制造可以涵盖全部团队工作流的QC标准**

- **决策:** 否决。暂时没有更好的统一方法，仅单方面提供两种QC方式，团队可自由制定标准、分配任务。

Future Work

- 优化QC体验，distribute体验和UI/UX